


Olasılık ve İstatistik - 1. Hafta



Giriş ve Temel Kavramlar

Prof. Dr. Rüya ŞAMLI





Σ %



Olasılık ve İstatistik

- Olasılık: Belirsizlik durumlarının matematiksel ifadesi
- İstatistik: Verilerin toplanması, düzenlenmesi, analiz edilmesi
- Olasılık, istatistiğin matematiksel temelidir

Anakütle, Örneklem, Parametre, İstatistik

- Anakütle/Popülasyon (Population): İncelenen tüm bireyler
- Örneklem (Sample): Anakültleden seçilen alt grup
- Parametre: Anakütleye ait özellik (μ)
- İstatistik: Örneklemden hesaplanan değer (\bar{x})

Anakütle ve Örneklem




Anakütle, Örneklem, Parametre, İstatistik


- **Anakütle/Popülasyon (Population)**
- Bir ormandaki **tüm sincaplar**.
- **Örneklem (Sample)**
- Bu ormandan rastgele seçilmiş **50 sincap**.
- Tüm sincapları incelemek çok zor ve zaman alıcı olacağından, içlerinden belirli bir grup seçip çalışmayı bu grup üzerinden yaparız.
- **Parametre (Parameter)**
- Ormandaki **tüm sincapların ortalama kilosu**.
- Bu değer sabittir (ama genellikle bilinmez). Biz örneklem üzerinden tahmin etmeye çalışırız.

Anakütle, Örneklem, Parametre, İstatistik


- **Popülasyon:** Ormandaki tüm sincaplar
- **Örneklem:** Rastgele seçilen 50 sincap
- **Parametre:** Tüm sincapların gerçek ortalama kilosu



POPÜLASYON



ÖRNEKLEM



PARAMETRE

Tüm sincapların
ortalama kilosu

Veri Türleri

- Nitel (Qualitative): Kategorik veriler
- Nicel (Quantitative): Sayısal veriler
 - - Kesikli (Discrete)
 - - Sürekli (Continuous)

Veri Türleri


- **Nitel (Qualitative): Kategorik veriler**
- Kuşların tüy renkleri (kırmızı, mavi, yeşil...)
- Balıkların yaşadıkları su türü (tatlı su, tuzlu su)
- Köpeklerin ırkları (Golden Retriever, Kangal, Bulldog...)
- Kaplanların yaşam alanı (orman, savan, dağlık bölge)
- Arıların görevleri (işçi, kraliçe, erkek arı)

Veri Türleri


Nitel (Qualitative): Kategorik veriler



Tüy rengi:
kırmızı



Yaşadığı su türü:
tatlı su



Irk:
Labrador Retriever



Yaşam alanı:
orman

Veri Türleri

- **Nicel (Quantitative): Sayısal veriler**
- Kuşların kanat uzunluğu (cm)
- Balıkların ağırlığı (kg)
- Köpeklerin yaşı (yıl)
- Kaplanların bir günde kat ettiği mesafe (km)
- Arıların kovandan topladığı nektar miktarı (gram)


Veri Türleri

- **Kesikli (Discrete) Veriler**
- Sayılabilen değerlerdir.
- Kesikli veriler tam sayılarla ifade edilir ve sayılar arasında ara değerler yoktur.


- Bir kümesteki tavuk sayısı (12 tavuk, 13 tavuk...)
- Bir balıkçı ağındaki balık sayısı
- Bir köpeğin doğurduğu yavru sayısı
- Bir çiftlikteki inek sayısı
- Bir arı kovanındaki arı sayısı

Veri Türleri


Nicel (Quantitative): Sayısal veriler



Kanat uzunluğu
(cm): 15



Ağırlık (kg):
3




Yaş (yıl): 4




Bir günde kat ettiği
mesafe (km): 8

Veri Türleri


Kesikli (Discrete) Veriler



Tavuk sayısı:
12



Balık sayısı
7




Yavru sayısı:
5



Inek sayısı
9


Veri Türleri

- Kesikli (Discrete) Veriler




Veri Türleri

- Kesikli (Discrete) Veriler



Veri Türleri

- **Kesikli (Discrete) Veriler**



Veri Türleri

- **Sürekli (Continuous) Veriler**
- **Sürekli (Continuous) veriler**, belli bir aralıkta sonsuz değer alabilen ve ölçümle ifade edilen nicel verilerdir.


Veri Türleri

- Sürekli (Continuous) Veriler

Veri Türleri

Sürekli (Continuous) Veriler


Bir Yıl Boyunca Bir Şehrin Günlük Sıcaklık Değerleri



Veri Türleri


Sürekli (Continuous) Veriler

Bir Çocuğun Boyunun Yıllara Göre Değişimi



Veri Türleri

Sürekli (Continuous) Veriler



Ölçüm Ölçekleri

- Nominal: Sınıflandırma
- Ordinal: Sıralama
- Interval: Sıralama + fark, mutlak sıfır yok
- Ratio: Sıralama + fark + mutlak sıfır

Ölçüm Ölçekleri

1. Nominal (Sınıflandırma)

- 👉 Sadece kategoriler vardır, sıralama yoktur.
- Hayvan türleri: kedi, köpek, kuş
- Kan grupları: A, B, AB, 0
- Göz rengi: mavi, kahverengi, yeşil

Ölçüm Ölçekleri

2. Ordinal (Sıralama)

 Sıralama vardır ama aradaki farklar ölçülemez.

- Eğitim düzeyi: ilkokul < ortaokul < lise < üniversite
- Yarış sırası: 1., 2., 3.
- Anket yanıtları: "katılmıyorum", "kararsızım", "katılıyorum"

Ölçüm Ölçekleri

3. Interval (Sıralama + fark, mutlak sıfır yok)

👉 Farklar ölçülebilir ama gerçek sıfır noktası yoktur.

- Sıcaklık ($^{\circ}\text{C}$ veya $^{\circ}\text{F}$): 20°C ile 30°C arasındaki fark 10°C 'dir, ama 0°C "hiç sıcaklık yok" demek değildir.
- Takvim yılları: 2000 ile 2010 arasındaki fark 10 yıldır, ama "0 yılı" başlangıç değil.
- IQ test puanları

Ölçüm Ölçekleri

4. Ratio (Sıralama + fark + mutlak sıfır)

👉 Hem sıralama hem fark vardır, ayrıca mutlak sıfır anlamlıdır.

- Kilo (kg): 0 kg demek hiç ağırlık yoktur.
- Boy (cm): 0 cm = hiç uzunluk yok.
- Gelir (₺): 0 gelir = hiç para yok.
- Yaş (yıl): 0 yaş = doğum anı.

NOMINAL

Sınıflandırma



hayvan türleri

ORDINAL


Sıralama

- 1.
- 2.
- 3.

yarış sırası

INTERVAL


Sıralama + fark
mutlak sıfır yok



sıcaklık ($^{\circ}\text{C}$)

RATIO

Sıralama + fark +
mutlak sıfır



boy (cm)

Ölçüm Ölçekleri Tablosu

Ölçüm Ölçekleri

Ölçek	Özellikler	Örnek
Nominal	Sadece sınıflandırma	Programlama dili: Python, C++, Java
Ordinal	Sıralama var, fark anlamsız	Başarı: düşük, orta, yüksek
Interval	Sıralama + fark, mutlak 0 yok	Sıcaklık (°C)
Ratio	Sıralama + fark + mutlak 0	İşlem süresi (ms), bellek (GB)

Bilgisayar Mühendisliğinde Kullanım Alanları

- Makine öğrenmesi: Model eğitimi, hata oranı
- Veri tabanı: Sorgu optimizasyonu
- Ağ güvenliği: Trafik analizi
- Performans analizi: Yazılım hız testleri

Bilgisayar Mühendisliğinde Kullanım Alanları

- **Makine öğrenmesi**
- **Naive Bayes Sınıflandırıcı:** Bir e-postanın spam olup olmadığını belirlerken, her kelimenin spam olma olasılığını hesaplar. Örnek: "bedava", "kazan", "hemen" kelimeleri yüksek spam olasılığına işaret edebilir.
- **Markov Zincirleri:** Bir kullanıcının bir web sitesindeki sonraki tıklamasını tahmin etmek için olasılıklardan yararlanılır.
- **Monte Carlo Simülasyonları:** Belirsizlik içeren durumlarda (örneğin finansal risk analizi) rastgele örnekleme yaparak sonuçların dağılımı hesaplanır.

Bilgisayar Mühendisliğinde Kullanım Alanları

- **Makine öğrenmesi**
- **Veri Dağılımlarını Anlamak:** Öğrencilerin sınav notlarının ortalama, medyan ve standart sapmasına bakarak başarı seviyesini ölçmek.
- **Regresyon Analizi:** Ev fiyatlarını tahmin etmek için: oda sayısı, metrekare, konum gibi değişkenler ile fiyat arasındaki istatistiksel ilişki kurulur.
- **Hipotez Testleri:** Yeni bir ilaç ile mevcut tedavinin etkisini kıyaslamak için istatistiksel anlamlılık testleri yapılır.

Bilgisayar Mühendisliğinde Kullanım Alanları

OLASILIK




Naive Bayes sınıflandırıcı



Markov zincirleri




Monte Carlo simülasyonları



İSTATİSTİK



Veri dağılımlarını anlamak



Regresyon analizi



Hipotez testleri

Bilgisayar Mühendisliğinde Kullanım Alanları

- **Veri tabanı: Sorgu optimizasyonu**
- **Sorgu Optimizasyonu (Query Optimization)**
- Veri tabanı yönetim sistemleri (ör. PostgreSQL, Oracle), sorgu planını seçerken tabloların boyutları ve olasılıksal tahminler üzerinden karar verir.
- Örnek: `SELECT * FROM müşteriler WHERE yaş > 30` sorgusunda, $\text{yaş} > 30$ koşulunu sağlayan kayıtların oranı olasılık tahminiyle hesaplanır.
- **Veri Madenciliği / Tahminleme**
- Veri tabanında kayıtlı müşterilerin satın alma davranışları üzerinden olasılıksal modeller kurulur.👉 Örnek: Bir müşterinin belirli bir ürünü satın alma olasılığını Naive Bayes ile tahmin etmek.

Bilgisayar Mühendisliğinde Kullanım Alanları

- **Veri tabanı: Sorgu optimizasyonu**
- **İndeks ve İstatistik Tabloları**
- Çoğu veri tabanı sistemi, tablolar için istatistiksel özetler (ortalama, minimum, maksimum, dağılım) tutar.
- Bu sayede sorgular daha hızlı çalışır çünkü sistem verinin nasıl dağıldığını bilir.

- **Veri Kalitesi ve Anomali Tespiti**
- Tablo sütunlarındaki değerlerin ortalama ve standart sapması alınarak sıra dışı kayıtlar bulunabilir.
- Örnek: Normalde 20–60 yaş arası olan bir müşteri tablosunda "150 yaşında" bir kayıt bulunursa istatistiksel olarak anomali kabul edilir.

- **Veri Öztleme**
- Örneğin, bir satış tablosunda ortalama satış miktarı, medyan, standart sapma gibi özet istatistikler hesaplanır.


Bilgisayar Mühendisliğinde Kullanım Alanları

- **Ağ güvenliği: Trafik analizi**
- **Saldırı Tespiti (Intrusion Detection)**
- Belirli bir IP'den gelen paketlerin saldırısı olma olasılığı hesaplanır.
- Örnek: Bir IP'den saniyede 1000'den fazla paket geliyorsa, bunun DDoS olma olasılığı çok yüksektir.
- **Bayesçi Yöntemler**
- Ağ trafigini “normal” veya “anormal” olarak sınıflandırmak için Naive Bayes kullanılır.
- Örnek: Paket boyutu, port numarası, protokol bilgisine göre saldırısı olasılığı çıkarılır.
- **Markov Zincirleri**
- Trafik akışının sıradaki durumunu (örneğin HTTP isteği sonrası beklenen yanıt) olasılıkla tahmin eder.

Bilgisayar Mühendisliğinde Kullanım Alanları

- **Ağ güvenliği: Trafik analizi**
- **Ortalama ve Standart Sapma ile Anomali Tespiti**
 - Normalde 100–200 ms arası olan ağ gecikmesinde aniden 2000 ms görülürse, bu istatistiksel olarak anormaldir.
- **Frekans Dağılımları**
 - Paket türlerinin (TCP, UDP, ICMP) dağılımı incelenerek olağandışı bir artış olup olmadığı analiz edilir.
- **Korelasyon Analizi**
 - Farklı portlardaki trafik hacimleri arasındaki ilişki incelenir. Aynı anda artış varsa koordineli saldırı şüphesi oluşur.
- **Zaman Serisi Analizi**
 - Trafik hacmi belirli aralıklarla izlenir ve olağan dışı artışlar (ör. spam trafigi) tespit edilir.

Bilgisayar Mühendisliğinde Kullanım Alanları



Bilgisayar Mühendisliğinde Kullanım Alanları

- **Performans analizi: Yazılım hız testleri**
- **Yanıt Süresi Dağılımı**
- Bir web servisinin yanıt süresinin belirli bir eşik altında olma olasılığı hesaplanır.
- Örnek: “Bir API isteğininki 200 ms’den kısa sürede tamamlanma olasılığı %85.”
- **Kuyruk Teorisi (Queueing Theory)**
- Sunucuların gelen istekleri karşılama ihtimalini modellemek için olasılık dağılımları (Poisson, Exponential) kullanılır.
- **Aşırı Yük Senaryoları**
- Belirli sayıda eşzamanlı kullanıcı geldiğinde sistemin çökme olasılığı tahmin edilir.

Bilgisayar Mühendisliğinde Kullanım Alanları

- **Performans analizi: Yazılım hız testleri**
- **Ortalama, Medyan, Yüzdelikler**
- Performans testlerinde sadece ortalama değil, medyan ve %95 yüzdelik gibi ölçüler raporlanır.
- Örnek: Ortalama yanıt süresi 180 ms, ama %95 kullanıcı 250 ms'den kısa sürede yanıt alıyor.
- **Standart Sapma ve Varyans**
- Yanıt sürelerinin ne kadar değişken olduğunu ölçer.
- Düşük standart sapma = daha kararlı sistem.
- **Hipotez Testi**
- Yeni bir algoritmanın eskisine göre daha hızlı olup olmadığı istatistiksel olarak test edilir.
- **Regresyon Analizi**
- Donanım kaynakları (CPU, RAM) ile yazılım performansı arasındaki ilişki incelenir.

Bilgisayar Mühendisliğinde Kullanım Alanları



Örnek Problemler

- 1. Bir sınıfta 60 öğrenci var. 10 Python, 25 C++, 25 Java kullanıyor.
 - Veri türü nedir?
 - Ölçüm ölçüği nedir?
- 2. Bir yazılım firmasında aylık hata sayısı kaydediliyor.
 - Kesikli mi, sürekli mi?
 - Ortalama/standart sapma hesaplanabilir mi?

Küçük Ödev

- 1. En az 3 soruluk küçük bir anket tasarlayın.
- - Her sorunun veri türünü ve ölçüm ölçegini belirleyin.
- 2. Topladığınız verilerden tablo oluşturun ve yorumlayın.